

Динамика связывания Foxd3 в развитии zebrafish

Homework 2 - ChIP-seq

75% epiboly → 1-2 somite stage → 5-6 somite stage → 14 somite stage

Самостоятельно проанализированы стадии 75ep и 1-2ss; для сравнения использованы результаты четырёх стадий развития: 75ep, 1-2ss, 5-6ss и 14ss.

Дата формирования: 2026-09-27

1. Цель работы

Охарактеризовать изменение genomic binding landscape транскрипционного фактора Foxd3 от гастрюляции (75ep) до миграции neural crest (14ss), одновременно отделяя наблюдаемые биологические различия от различий глубины, enrichment и общего качества ChIP-seq.

2. Данные и воспроизводимость

Для стадий 75ep и 1-2ss использовались парные Foxd3 ChIP и Input nuclear BAM-файлы; эти две стадии были проанализированы самостоятельно. Координатной основой служил reference genome Danio rerio GRCz11 с соответствующей gene annotation. Для межстадийного сравнения дополнительно использованы результаты 5-6ss и 14ss: CPM BigWig tracks, log2(ChIP/Input), MACS3 peaks, summits, FRiP и profiles вокруг summit.

Стадия	Роль	ChIP/Input
75ep	самостоятельный анализ	nuclear BAM pair
1-2ss	самостоятельный анализ	nuclear BAM pair
5-6ss	предоставленные результаты	signal, peaks и summary figures
14ss	результаты для сравнения	ChIP/Input и результаты анализа

3. Методы

Для стадий, обработанных по единому workflow, выполнены samtools flagstat; bamCoverage с CPM normalization, binSize 10 и 4 потоками; bigwigCompare log2(ChIP/Input) с pseudocount 1 и binSize 10; MACS3 callpeak в paired-end режиме (BAMPE), effective genome size 1.36×10^9 , $q \leq 0.01$; FRiP по семинарному определению; computeMatrix вокруг summit ± 2000 bp с binSize 20; plotHeatmap и plotProfile. Параметры анализа сохранялись одинаковыми для сопоставимости результатов.

FRiP = число ChIP alignments, пересекающих narrowPeak / общее число ChIP alignments. Направленный overlap A→B - доля интервалов A, имеющих хотя бы одно пересечение с B; он не равен Jaccard. Jaccard рассчитан bedtools по покрываемым основаниям: intersection/union.

4. Форматы файлов

Формат	Что хранит	Text/Binary	Использование
FASTA	референсную последовательность GRCz11	text	координатная система и reference genome
GTF	координаты генов/транскриптов/экзонов и атрибуты	text	gene annotation в IGV
BAM	сжатые выравнивания reads/fragments на genome	binary	исходные ChIP и Input alignments
BAI	индекс BAM по genomic coordinates	binary	быстрый доступ к отдельным регионам
BigWig	индексированный непрерывный coverage/signal track	binary	CPM ChIP/Input и log2 ratio в IGV
BED	genomic intervals в 0-based half-open coordinates	text	summits, genes, interval operations
narrowPeak	BED6+4: interval, signalValue, -log10(p), -log10(q), summit offset	text	дискретные enriched regions от MACS3
MACS3 peaks.xls	текстовую таблицу peaks и metadata вызова (start/end, summit, pileup, p/q, fold enrichment)	text (не Excel binary)	аудит параметров и подробных peak metrics
TSV	таблицы с полями, разделёнными tab	text	QC, FRiP и comparisons
deepTools matrix.gz	gzip-сжатую матрицу regions × genomic bins для нескольких samples плюс metadata	compressed text/binary container	вход plotHeatmap/plotProfile
PDF	готовые векторные/растровые страницы графиков и отчёта	binary	визуализация и сдача

Ключевая цепочка: BAM (отдельные alignments) → BigWig (непрерывный количественный signal) → narrowPeak (дискретные статистически обогащённые регионы).

5. BAM QC, peak calling и enrichment

Stage	ChIP alignments	Input alignments	Peaks	FRiP	median signalValue	max -log10(q)
75ep	23,863,894	39,931,858	36	0.000172	5.79	100.05
1-2ss	12,816,614	33,460,348	40	0.000140	6.11	56.18
5-6ss	18,853,396	57,051,062	839	0.002360	5.52	163.70
14ss	41,553,880	27,794,668	170	0.001621	3.29	321.45

Для 5-6ss число ChIP alignments взято из denominator предоставленной таблицы FRiP; число Input alignments вычислено как $2 \times 28,525,531$ paired fragments, записанных MACS3 в peaks.xls. Поэтому глубины сопоставимы как alignment counts, однако для этой стадии отсутствует отдельная статистика flagstat.




Рисунок 1. Сравнение количества peaks, FRiP и median narrowPeak signalValue. Enrichment strength не подменяется одной придуманной метрикой: показаны независимые сопоставимые summaries.

Наиболее значимые peaks

Stage	Coordinates	signalValue	-log10(p)	-log10(q)	q
75ep	NC_007113.7:33276015-33276551	21.7013	109.261	100.05	0.8913e-100
1-2ss	NC_007113.7:33276063-33276596	21.2286	65.2724	56.183	0.6561e-56
5-6ss	NC_007117.7:32206484-32207024	21.1014	172.913	163.701	0.1991e-163
14ss	NC_007126.7:35583507-35583991	24.9995	330.35	321.453	0.3524e-321

narrowPeak хранит $Q = -\log_{10}(q)$; действительный q восстановлен как 10^{-Q} . Координаты в таблице показаны человеку как 1-based inclusive, тогда как исходные BED/narrowPeak start являются 0-based.

6. Heatmaps и average profiles вокруг summit

Матрицы построены по ChIP CPM и Input CPM вокруг центров MACS3 summits (± 2 kb, 20-bp bins). Каждая строка heatmap соответствует peak; profile показывает средний signal по всем peaks данной стадии.

75ep




Рисунок: 75ep heatmap (слева) и average profile (справа), Foxd3 ChIP против Input.

1-2ss




Рисунок: 1-2ss heatmap (слева) и average profile (справа), Foxd3 ChIP против Input.

5-6ss




Рисунок: 5-6ss heatmap (слева) и average profile (справа), Foxd3 ChIP против Input.

14ss




Рисунок: 14ss heatmap (слева) и average profile (справа), Foxd3 ChIP против Input.

7. Попарное сравнение genomic intervals

A vs B	Peaks A/B	A→B overlap	B→A overlap	Jaccard
75ep vs 1-2ss	36 / 40	12 (33.3%)	12 (30.0%)	0.17371
75ep vs 5-6ss	36 / 839	22 (61.1%)	22 (2.6%)	0.02271
75ep vs 14ss	36 / 170	18 (50.0%)	18 (10.6%)	0.07514
1-2ss vs 5-6ss	40 / 839	30 (75.0%)	30 (3.6%)	0.02813
1-2ss vs 14ss	40 / 170	12 (30.0%)	12 (7.1%)	0.04263
5-6ss vs 14ss	839 / 170	40 (4.8%)	40 (23.5%)	0.03694

A→B и B→A имеют разные denominators и поэтому приведены отдельно. Pair-specific A-only = peaks_A – A→B overlap; global stage-specific ниже означает отсутствие пересечения сразу со всеми тремя другими стадиями.




Рисунок 2. Jaccard между peak sets (слева) и число globally stage-specific called peaks (справа).

Наиболее похожая пара по Jaccard: **75ep и 1-2ss** ($J=0.17371$); наиболее различающаяся: **75ep и 5-6ss** ($J=0.02271$). Низкий Jaccard и большое число globally specific calls указывают на выраженную перестройку набора вызванных peaks, но ещё не доказывают полное биологическое исчезновение binding: сигнал может опуститься ниже порога peak calling.

8. IGV-примеры

Для каждого locus показаны gene annotation, CPM ChIP и Input, $\log_2(\text{ChIP}/\text{Input})$ и narrowPeak tracks четырёх стадий. Первый пример демонстрирует сильный peak 5-6ss, второй - region с peak на нескольких стадиях, третий - выраженный stage-specific region.

IGV_1: strong 5-6ss

NC_007114.7:14906146-14922787 | anchor: 5-6ss | nearest gene: nfixb



IGV_1: NC_007114.7:14906146-14922787. Опорная стадия 5-6ss, ближайший ген nfixb (0 bp). Сильный 5-6ss peak с максимальным signalValue.

IGV_2: multi_stage_shared

NC_007129.7:44262527-44278905 | anchor: 5-6ss | nearest gene: LOC137488334



IGV_2: NC_007129.7:44262527-44278905. Опорная стадия 5-6ss, ближайший ген LOC137488334 (0 bp). Общий region с peak на 75ep, 1-2ss, 5-6ss и 14ss; высота enrichment различается между стадиями.

IGV_3: global_stage_specific

NC_007112.7:257235-265511 | anchor: 5-6ss | nearest gene: cenpe



IGV_3: NC_007112.7:257235-265511. Опорная стадия 5-6ss, ближайший ген *cenpe* (0 bp). Сильный 5-6ss peak, не пересекающий вызванные peaks трёх остальных стадий.

9. Биологическая интерпретация и ограничения

A. Наблюдаемые изменения binding landscape

Набор вызванных Foxd3 peaks не остаётся постоянным. Максимальное число peaks наблюдалось на стадии **5-6ss** (839); pairwise Jaccard варьировал от 0.02271 до 0.17371. Одновременно сохраняются общие loci, продемонстрированные IGV_2, и появляются/исчезают stage-biased calls, как в IGV_3. Это согласуется с перестройкой occupation Foxd3 от gastrulation к формированию и миграции neural crest.

B. Свидетельства в пользу биологической интерпретации

Поддержку дают согласованные изменения координат peaks, наличие globally stage-specific интервалов и локальные различия ChIP/Input signal в IGV. Участки, которые перекрываются между несколькими стадиями и сохраняют положительный log2 enrichment, выглядят как относительно стабильные элементы программы Foxd3. Stage-specific peak calls с выраженным локальным ChIP-over-Input signal являются кандидатами на динамические regulatory elements.

C. QC и технические confounders

Наиболее высокий FRiP имела стадия **5-6ss** (0.002360), а наиболее высокий median signalValue - **1-2ss** (6.11). Различия в числе peaks нельзя объяснять только биологией: меняются library depth, background/Input, immunoprecipitation efficiency, fraction of reads in peaks, signal-to-noise и статистическая мощность MACS3. Отсутствие called peak означает отсутствие достаточной статистической поддержки при данном качестве/пороге, а не доказанное отсутствие binding.

ChIP-seq локализует оккупацию, но не устанавливает, активирует или репрессирует Foxd3 ближайший ген: enhancer может регулировать не ближайший promoter, а binding не эквивалентен изменению transcription. Для функциональной проверки нужны ATAC-seq (accessibility), H3K27ac ChIP-seq (active enhancer state) и RNA-seq (expression), желательно с perturbation Foxd3 и согласованным stage-matched design.

10. Вывод

Foxd3 binding landscape заметно меняется между 75ep, 1-2ss, 5-6ss и 14ss, сохраняя одновременно общий core loci и stage-biased regions. Направление развития согласуется с динамической regulatory program neural crest, однако величину биологической перестройки нельзя отделить от различий ChIP quality только по peak counts. Наиболее надёжны выводы, подтверждённые одновременно interval overlap, локальным ChIP/Input signal и независимыми omics-данными.

Приложение. Фактически использованный workflow

```
# Workflow из run_stage.slurm
for stage in 75ep 1-2ss 14ss; do
  chip="data/${stage}/foxd3_${stage}_chip.nuclear.bam"
  input="data/${stage}/foxd3_${stage}_input.nuclear.bam"
  chip_bw="results/signal/${stage}_Chip.CPM.bw"
  input_bw="results/signal/${stage}_input.CPM.bw"
  log2_bw="results/signal/${stage}.log2_IP_Input.bw"
  peakdir="results/peaks/${stage}"
  peaks="$peakdir/${stage}_peaks.narrowPeak"
  summits="$peakdir/${stage}_summits.bed"

  # BAM QC
  samtools flagstat -@ 4 "$chip" > "results/tables/${stage}_chip.flagstat.txt"
  samtools flagstat -@ 4 "$input" > "results/tables/${stage}_input.flagstat.txt"

  # CPM BigWig для ChIP и Input
  bamCoverage -b "$chip" -o "$chip_bw" --normalizeUsing CPM \
    --binSize 10 --numberOfProcessors 4
  bamCoverage -b "$input" -o "$input_bw" --normalizeUsing CPM \
    --binSize 10 --numberOfProcessors 4
  bigwigCompare -b1 "$chip_bw" -b2 "$input_bw" --operation log2 \
    --pseudocount 1 --binSize 10 --numberOfProcessors 4 -o "$log2_bw"

  # Peak calling и top q-value
  macs3 callpeak -t "$chip" -c "$input" -f BAMPE -g 13600000000 \
    -n "$stage" -q 0.01 --outdir "$peakdir"
  sort -k9,9nr "$peaks" | sed -n '1,10p' > \
    "results/tables/${stage}_top10_peaks.tsv"
  Q=$(sort -k9,9nr "$peaks" | awk 'NR==1{print $9; exit}')
  awk -v Q="$Q" 'BEGIN{printf "q=%.4e\n",10^(-Q)}'

  # FRiP
  total=$(samtools view -@ 4 -c "$chip")
  inpeaks=$(samtools view -@ 4 -c -L "$peaks" "$chip")
  awk -v n="$inpeaks" -v d="$total" 'BEGIN{printf "%.8f\n",n/d}'

  # Matrix, heatmap и profile вокруг summit
  computeMatrix reference-point --referencePoint center -R "$summits" \
    -S "$chip_bw" "$input_bw" -b 2000 -a 2000 --binSize 20 \
    --numberOfProcessors 4 -o "results/figures/${stage}.matrix.gz"
  plotHeatmap -m "results/figures/${stage}.matrix.gz" \
    -out "results/figures/${stage}.heatmap.pdf" \
    --samplesLabel "Foxd3 ChIP" "Input" --refPointLabel summit
  plotProfile -m "results/figures/${stage}.matrix.gz" \
    -out "results/figures/${stage}.profile.pdf" \
    --samplesLabel "Foxd3 ChIP" "Input" --refPointLabel summit
done

# Four-stage comparison из compare_stages.py
stages=(75ep 1-2ss 5-6ss 14ss)
declare -A peakfiles=(
  [75ep]="results/peaks/75ep/75ep_peaks.narrowPeak"
  [1-2ss]="results/peaks/1-2ss/1-2ss_peaks.narrowPeak"
  [5-6ss]="data/5-6ss/foxd3_5-6ss_chip_peaks.narrowPeak"
  [14ss]="results/peaks/14ss/14ss_peaks.narrowPeak"
)
for s in "${stages[@]"; do
  bedtools sort -i "${peakfiles[$s]}" > "sorted/${s}.narrowPeak"
done

pairs=(
  ("75ep 1-2ss" "75ep 5-6ss" "75ep 14ss" \
    "1-2ss 5-6ss" "1-2ss 14ss" "5-6ss 14ss")
)
for pair in "${pairs[@]"; do
  read -r A B << "$pair"
  # Directed overlap A->B and B->A
  bedtools intersect -a "sorted/${A}.narrowPeak" \
    -b "sorted/${B}.narrowPeak" -u | wc -l
  bedtools intersect -a "sorted/${B}.narrowPeak" \
    -b "sorted/${A}.narrowPeak" -u | wc -l
  # Jaccard by genomic coverage
  bedtools jaccard -a "sorted/${A}.narrowPeak" \
    -b "sorted/${B}.narrowPeak"
done

# Global stage-specific peaks: no overlap with any other stage
for s in "${stages[@]"; do
  others=()
  for o in "${stages[@]"; do
    [[ "${s}" != "${o}" ]] && others+=("sorted/${o}.narrowPeak")
  done
  cat "${others[@]}" | bedtools sort -i - | bedtools merge -i - \
    > "${s}.others.union.bed"
  bedtools intersect -a "sorted/${s}.narrowPeak" \
    -b "${s}.others.union.bed" -v > "${s}.global_specific.narrowPeak"
done

# Координаты IGV: overlap membership и ближайшие гены
for o in 75ep 1-2ss 14ss; do
  bedtools intersect -a sorted/5-6ss.narrowPeak \
    -b "sorted/${o}.narrowPeak" -u > "5-6ss.shared_with_${o}.bed"
done
bedtools closest -a candidate_pool.bed -b reference/genes.bed -d

# Core fragment из prepare_igv_assets.py (Python)
with pyBigWig.open(source_bw) as bw:
  intervals = bw.intervals(chrom, view_start, view_end) or []
# GTF оставлен для features, пересекающих выбранные loci.

python scripts/compare_stages.py
python scripts/prepare_igv_assets.py
```

Полные версии использованных scripts сохранены как run_stage.slurm, compare_stages.py и prepare_igv_assets.py.