

Домашняя работа 1: Metagenomics

Изменение почвенного микробиома после загрязнения керосином

В эксперименте сравнивали контрольную почву без керосина (k0), слабое загрязнение (k5, 5 г керосина на кг почвы) и сильное загрязнение (k25, 25 г/кг). Образцы собирали на 3, 90, 180 и 360 день, по три биологических повтора для каждой комбинации условий (всего 36 образцов). Ампликоны 16S rRNA V4-V5 секвенировали на Illumina MiSeq PE250, но в анализе использовали только forward R1 reads.

Этап	Использованные параметры
DADA2	trim-left 25; trunc-len 200; max-ee 3; pseudo-pooling; consensus chimeras; parent fold 4
Taxonomy	Учебный GreenGenes2 V4 naive-Bayes classifier
Core metrics	Phylogenetic metrics при sampling depth 4500; сохранены все 36 образцов

Результаты и ответы

Задача 1. FASTQC одного R1 образца

Для проверки выбрали образец SRR17307316 (k0, день 3, повтор 1). В нём было 10 833 reads длиной 251 nt, GC-состав 57%, reads низкого качества не отмечены. Модуль per-base sequence quality получил статус pass. В первых пяти позициях среднее качество составляло примерно Q32-Q33, в центральной части - в основном Q34-Q38, а в последнем интервале 250-251 - Q32,67. К 3'-концу разброс качества увеличивался (10-й перцентиль Q19,5), но медиана оставалась Q36. В целом качество R1 высокое, хотя на конце read заметно умеренное снижение.




Рисунок 1. Стандартный FASTQC plot качества по позициям для SRR17307316 R1.

Задача 2. Почему слева удаляли 25 нуклеотидов?

В начале read находится forward primer и прилегающая техническая область (515F: GTGCCAGCMGCCGCGGTAA, 19 nt). Параметр `--p-trim-left 25` удаляет primer и несколько следующих начальных оснований, как задано в workflow. Благодаря этому primer и возможные несовпадения в нём не воспринимаются как биологические различия между ASV. Все reads обрезаются одинаково перед построением error model.

Задача 3. Статистика DADA2 и качество данных

Этап	Число reads	% от input
Input	641 362	100,00%
Filtered	638 869	99,61%
Denoised	622 542	97,07%
Non-chimeric	608 362	94,85%

После полного workflow DADA2 сохранилось 94,85% исходных reads. Максимальное число non-chimeric reads было у SRR17307475 - 43 518, минимальное у SRR17307380 - 4 809. Высокая доля сохранённых reads согласуется с результатом FASTQC. Глубина между образцами различается примерно в девять раз, поэтому sampling depth 4500 выбрали ниже наблюдаемого минимума; при этом в анализе сохранились все образцы.




Рисунок 2. Сохранение reads на этапах DADA2 для всех 36 образцов.

Задача 4. Почему подходит V4 classifier?

PCR primers охватывали область V4-V5, но мы анализировали только forward R1 reads. После удаления 25 оснований слева и truncation на позиции 200 сохранённая последовательность начинается со стороны 515F и в основном перекрывает V4. Поэтому classifier, обученный на соответствующем участке V4, может классифицировать эти частичные reads. Для taxonomy не обязательно иметь полный V4-V5 amplicon, но read должен перекрываться с областью, на которой обучен classifier.

Задача 5. Таксономический состав

Level 3 (class)

На 3 день состав трёх вариантов был похож. Acidobacteriae составляли 18,1-19,5%, Alphaproteobacteria - 16,1-17,0%, Actinomycetia - 10,5-11,2%, Gammaproteobacteria - 9,3-10,4%, Thermoleophilia - 7,4-8,7%. Затем траектории разошлись. На 360 день в k0 и k5 преобладали Acidobacteriae (47,9% и 46,1%). В k25 доля Gammaproteobacteria достигла 87,5%, а Acidobacteriae снизилась до 1,2%. Значит, сильное загрязнение сопровождалось выраженным отбором и доминированием одного класса.




Рисунок 3. Средний состав на Level 3 для каждой группы и временной точки (n=3).

Level 6 (genus)

Среди классифицированных родов в загрязнённых образцах наиболее обильным был *Paraburkholderia_580243*: в среднем 25,84% для k5 и k25. Особенно заметно его доля увеличилась в k25 - 26,7% на 90 день, 50,7% на 180 день и 83,6% на 360 день. По нашим данным этот genus явно связан с сильным загрязнением керосином и поздними временными точками. Однако 16S taxonometry показывает только состав сообщества и ассоциацию с условием; она не доказывает функцию этих ASV и не позволяет напрямую утверждать, что именно они разрушают керосин.




Рисунок 4. Средний состав на Level 6 для каждой группы и временной точки (n=3).

Задача 6. Weighted UniFrac

Первые три PCoA axes объясняют 55,7%, 25,3% и 7,0% вариации соответственно, вместе - 88,0%.

Поэтому основное разделение видно по Axis 1, затем по Axis 2 и Axis 3. На 3 день k0, k5 и k25 расположены близко: трёхмерное расстояние от центроидов k5 и k25 до соответствующего центроида k0 составляет только 0,026 и 0,047. В следующие сроки обе загрязнённые группы смещаются в положительную сторону Axis 1. Для k25 это смещение последовательно усиливается до 360 дня.

Для k5 расстояние до k0 увеличивается до 0,146 на 90 день и 0,206 на 180 день, а затем уменьшается до 0,159 на 360 день. Это похоже на частичное восстановление, главным образом за счёт возврата по Axis 1. При этом поздний центроид k5 всё ещё отличается по Axis 2 и Axis 3, поэтому восстановление нельзя считать полным. Для k25 расстояние растёт от 0,047 до 0,155, 0,275 и 0,379. Признаков восстановления после сильного загрязнения за 360 дней не видно.




Рисунок 5. Weighted UniFrac PCoA. Полупрозрачные символы показывают отдельные образцы. Сплошные линии соединяют центроиды одной группы строго по времени: d3 -> d90 -> d180 -> d360; это временные траектории, а не fitted curves.

Задача 7. Alpha diversity по Shannon

На 3 день Shannon diversity была почти одинаковой во всех вариантах: средние значения 8,98 для k0, 9,05 для k5 и 8,91 для k25. В контроле показатель снижался постепенно: 8,87 на 90 день, 8,65 на 180 день и 8,28 на 360 день. В k5 diversity снизилась до 7,79 и 6,58, а затем немного выросла до 6,80 на 360 день. Это согласуется с частичным, но неполным восстановлением. В k25 снижение было непрерывным и намного сильнее: 7,61, 5,91 и 2,95. Значит, сильное загрязнение керосином сопровождалось большой потерей alpha diversity без восстановления к 360 дню.




Рисунок 6. Shannon entropy по вариантам и времени: среднее $\pm$ SD, $n=3$.

Воспроизводимость анализа

В QIIME2 импортировали 36 forward R1 FASTQ как SampleData[SequencesWithQuality] в формате SingleEndFastqManifestPhred33V2. Основные команды и параметры:

- qiime dada2 denoise-single --p-trim-left 25 --p-trunc-len 200 --p-max-ee 3 --p-n-threads 20 --p-pooling-method pseudo --p-chimera-method consensus --p-min-fold-parent-over-abundance 4
- qiime feature-classifier classify-sklearn --p-n-jobs 16 (учебный GreenGenes2 V4 classifier)
- qiime phylogeny align-to-tree-mafft-fasttree
- qiime diversity core-metrics-phylogenetic --p-sampling-depth 4500
- qiime diversity alpha-group-significance (Shannon vector и полная metadata)

Sampling depth 4500 выбран ниже минимального наблюдаемого значения 4809 reads, поэтому сохранились все 36 образцов. На рисунках 3 и 4 показаны средние sample-level relative abundances. Для оценки восстановления по Weighted UniFrac использовали расстояния между центроидами, рассчитанные по PCoA Axes 1-3.